efrei
INGÉNIEURS - NUMÉRIQUE
PARIS PANTHÉON-ASSAS UNIVERSITÉ

Analyse et prédiction des recettes à fort trafic

Analyse exploratoire et
modèles de classification

Régression logistique · Random Forest · Gradient Boosting

Contexte et objectif

Le site de recettes veut vendre des abonnements. Plus une recette attire de visites, plus la probabilité d'une vente augmente.

Objectif : prédire quelles recettes entraîneront un fort trafic, pour choisir celles à mettre en avant.

947 recettes

8 variables

10 catégories

61 % fort trafic

Variables : calories, glucides, sucre, protéines, catégorie, portions → cible `high_traffic`

1

Analyse exploratoire

Nettoyage, distributions et liens avec le trafic

Données et nettoyage

1 Cible

Valeurs vides de `high_traffic` = « Low », puis codage 0 / 1.

2 Catégories

11 valeurs dans les données : « Chicken Breast » fusionné avec « Chicken » pour obtenir les 10 attendues.

3 Portions

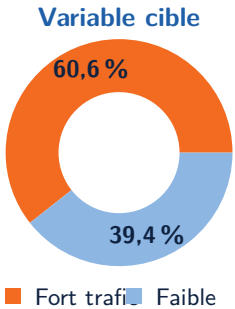
« 4 as a snack » et « 6 as a snack » ramenés à 4 et 6 ; colonne convertie en entier.

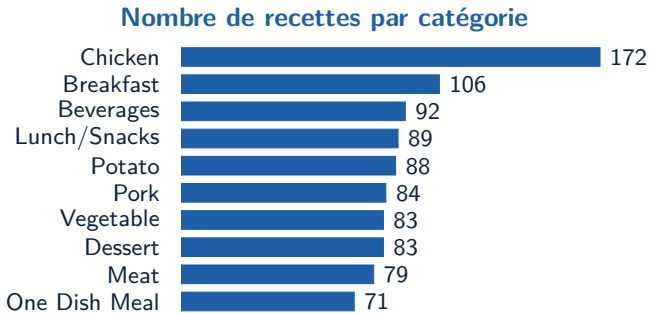
4 Valeurs manquantes

52 recettes (5,5 %) sans données nutritionnelles, imputées par la médiane de leur catégorie.

Aucun doublon, identifiant de recette unique.

Aperçu de la cible et des catégories





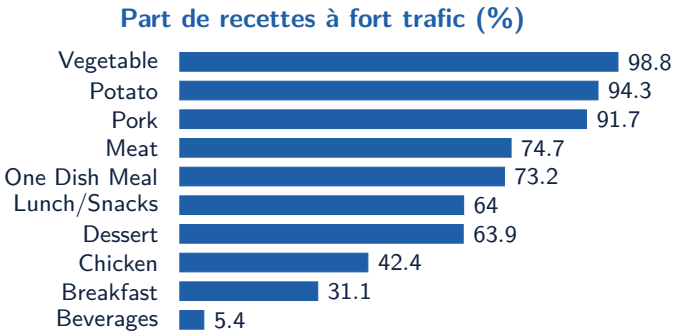
Classes modérément déséquilibrées (61 / 39) et catégories bien représentées (71 à 172 recettes).

Statistiques descriptives

Variable	Moyenne	Médiane	Maximum	Asymétrie
Calories	431,1	296,9	3 633	2,11
Glucides (g)	34,4	21,2	530	3,87
Sucre (g)	8,9	4,4	149	4,29
Protéines (g)	23,9	11,2	363	3,59

Moyennes bien supérieures aux médianes et valeurs extrêmes : distributions très asymétriques. Transformation `log1p` pour le modèle linéaire ; inutile pour les arbres.

La catégorie explique l'essentiel



0,58

V de Cramér

χ^2 : $p < 0{,}001$

De 5 % (boissons) à 99 % (légumes) : la catégorie est de loin la variable la plus discriminante.

Nutrition et trafic : effets faibles

Test de Mann-Whitney (fort trafic vs faible)

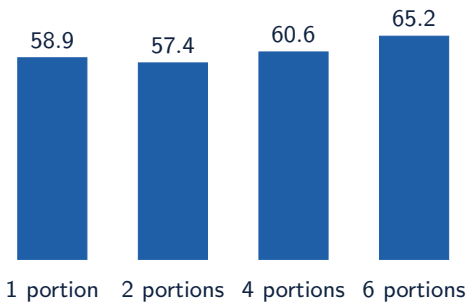
Variable	Statistique U	p-value
Calories	115 214	0,0472
Glucides	115 446	0,0412
Sucre	98 956	0,0491
Protéines	**120 705**	**0,0009**

Lecture

- Protéines : seul lien net avec la cible.
- Calories, glucides, sucre : p proche de 0,05, sans correction pour tests multiples.
- Effet bien plus faible que celui de la catégorie.

Portions et trafic : aucun lien

Taux de fort trafic selon les portions (%)



$$p = 0{,}43$$

test du χ^2

Les taux restent entre 57 % et 65 % : le nombre de portions ne distingue pas les recettes populaires.

Valeurs manquantes : un faux signal

Taux de fort trafic

59,8 %
nutrition renseignée
(895 recettes)

75,0 %
nutrition manquante
(52 recettes)

L'écart disparaît à catégorie égale : les manquants sont concentrés dans des catégories à fort trafic (aucun dans *Beverages* ni *Breakfast*). Le sens de l'écart change selon la catégorie.

Test en validation croisée (Random Forest)

	F1	ROC AUC
Avec	0,7996	0,8137
Sans	0,7910	0,8138

✓ **Variable retirée : AUC identique, aucun gain mesurable, modèle plus simple.**

Synthèse de l'exploration

1 Cible	61 % de fort trafic : classes modérément déséquilibrées, métriques F1 et AUC privilégiées.
2 Catégorie	Variable la plus discriminante ($V = 0{,}58$, de 5 % à 99 %) : conservée en one-hot.
3 Nutrition	Distributions asymétriques, effet faible : `log1p` pour le modèle linéaire.
4 Portions, manquants	Aucun effet propre : `nutrition_missing` retirée, portions gardées sans coût.

2

Modélisation

Régression logistique, Random Forest et Gradient Boosting

Démarche de modélisation

1 — Séparation
80 / 20 stratifiée
757 train · 190 test

2 — Prétraitement
Log + standardisation (linéaire), one-hot

3 — Validation croisée
5 plis stratifiés
F1, AUC, précision

4 — Optimisation
GridSearch sur le F1, 3 modèles

5 — Test final
Évaluation sur 190 recettes

Tout le prétraitement est dans des pipelines scikit-learn : pas de fuite de données entre entraînement et validation.

Trois modèles, des scores proches

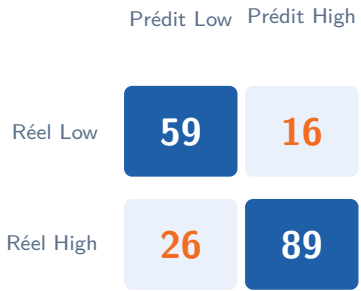
Modèle	F1 (CV)	Accuracy	Précision	Rappel	F1	ROC AUC
Régression logistique	**0,803**	**0,779**	**0,848**	**0,774**	**0,809**	**0,869**
Random Forest	0,796	0,753	0,788	0,809	0,798	0,852
Gradient Boosting	0,801	0,779	0,854	0,765	0,807	0,850

CV = validation croisée sur le jeu d'entraînement ; autres colonnes = jeu de test (190 recettes).

Écarts de F1 inférieurs à 0,02 : modèles équivalents. Retenu : la régression logistique (meilleure AUC, la plus simple et interprétable).

Le modèle retenu en détail

Matrice de confusion (test, 190 recettes)



0,85 Précision

Quand le modèle annonce un fort trafic, il a raison 85 fois sur 100.

0,77 Rappel

Il repère 77 % des recettes à fort trafic.

0,87 ROC AUC

Bonne capacité à classer les recettes.

Seuil de décision à 0,5.

Conclusion

À retenir

- La catégorie est le facteur dominant du trafic.
- La nutrition et les portions apportent peu.
- Régression logistique : F1 0,81 et AUC 0,87 sur le test.
- Les trois modèles sont équivalents ; le plus simple est retenu.

Limites et pistes

- Petit échantillon : 947 recettes, 190 en test.
- Pas de données sur les ingrédients ni le temps de préparation.
- Imputation calculée avant la séparation train / test : à intégrer au pipeline.
- Ajuster le seuil selon le coût d'une fausse promotion.

Ouvrir l'application interactive