efrei
INGÉNIEURS - NUMÉRIQUE
PARIS PANTHÉON-ASSAS UNIVERSITÉ

Analyse et prédiction des recettes à fort trafic

Analyse exploratoire et
modèles de classification

Céline ADOUSSINGANDE

Régression logistique · Random Forest · Gradient Boosting

Plan de la présentation

1. **Contexte et objectif**
2. **Analyse exploratoire** — nettoyage · liens
3. **Modélisation** — 3 modèles · ROC
4. **Conclusion et limites**

Fil conducteur

Quelles recettes mettre en avant pour maximiser le trafic, donc les ventes d'abonnements ?

Comprendre les données → identifier les facteurs du trafic → prédire.

Contexte et objectif

Le site de recettes veut vendre des abonnements. Plus une recette attire de visites, plus la probabilité d'une vente augmente.

Objectif : prédire quelles recettes entraîneront un fort trafic, pour choisir celles à mettre en avant.

947
recettes

8
variables

10
catégories

61 %
fort trafic

Variables : calories, glucides, sucre, protéines, catégorie, portions → cible `high_traffic`

1

Analyse exploratoire

Nettoyage, distributions et liens avec le trafic

Données et nettoyage

1 Cible

Valeurs vides de `high_traffic` = « Low », puis codage 0 / 1.

2 Catégories

11 valeurs dans les données : « Chicken Breast » fusionné avec « Chicken » pour obtenir les 10 attendues.

3 Portions

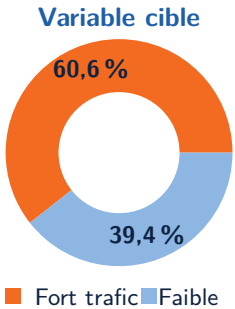
« 4 as a snack » et « 6 as a snack » ramenés à 4 et 6 ; colonne convertie en entier.

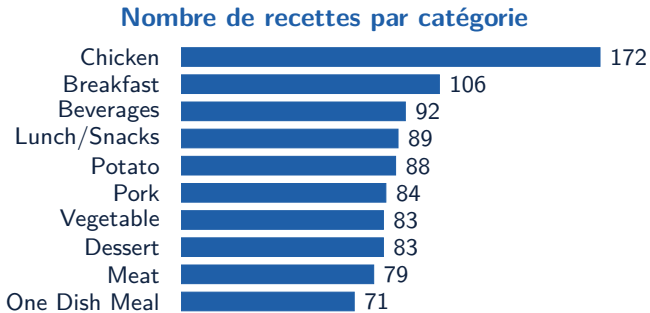
4 Valeurs manquantes

52 recettes (5,5 %) sans données nutritionnelles, imputées par la médiane de leur catégorie.

Aucun doublon, identifiant de recette unique.

Aperçu de la cible et des catégories





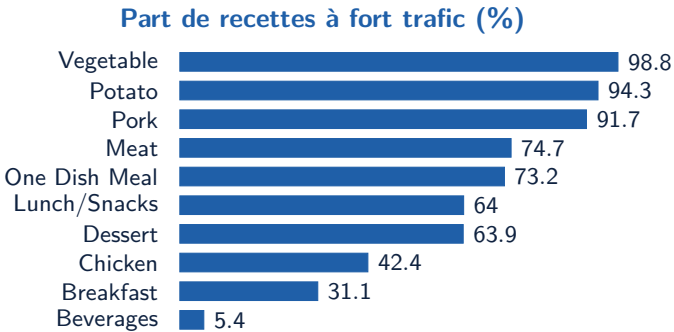
Classes modérément déséquilibrées (61 / 39) et catégories bien représentées (71 à 172 recettes).

Statistiques descriptives

Variable	Moyenne	Médiane	Maximum	Asymétrie
Calories	431,1	296,9	3 633	2,11
Glucides (g)	34,4	21,2	530	3,87
Sucre (g)	8,9	4,4	149	4,29
Protéines (g)	23,9	11,2	363	3,59

Moyennes bien supérieures aux médianes et valeurs extrêmes : distributions très asymétriques. Transformation `log1p` pour le modèle linéaire ; inutile pour les arbres.

La catégorie explique l'essentiel



0,58

V de Cramér

χ^2 : $p < 0{,}001$

De 5 % (boissons) à 99 % (légumes) : la catégorie est de loin la variable la plus discriminante.

Nutrition et trafic : effets faibles

Test de Mann-Whitney (fort trafic vs faible)

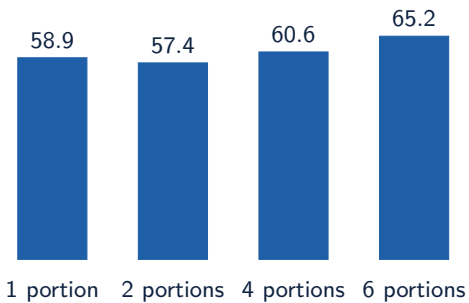
Variable	Statistique U	p-value
Calories	115 214	0,0472
Glucides	115 446	0,0412
Sucre	98 956	0,0491
Protéines	**120 705**	**0,0009**

Lecture

- Protéines : seul lien net avec la cible.
- Calories, glucides, sucre : p proche de 0,05, sans correction pour tests multiples.
- Effet bien plus faible que celui de la catégorie.

Portions et trafic : aucun lien

Taux de fort trafic selon les portions (%)



$$p = 0{,}43$$

test du χ^2

Les taux restent entre 57 % et 65 % : le nombre de portions ne distingue pas les recettes populaires.

Valeurs manquantes : un faux signal

Taux de fort trafic

59,8 %
nutrition renseignée
(895 recettes)

75,0 %
nutrition manquante
(52 recettes)

L'écart disparaît à catégorie égale : les manquants sont concentrés dans des catégories à fort trafic (aucun dans *Beverages* ni *Breakfast*). Le sens de l'écart change selon la catégorie.

Test en validation croisée (Random Forest)

	F1	ROC AUC
Avec	0,7996	0,8137
Sans	0,7910	0,8138

✓ **Variable retirée : AUC identique, aucun gain mesurable, modèle plus simple.**

Synthèse de l'exploration

1	**Cible**	61 % de fort trafic : classes modérément déséquilibrées, métriques F1 et AUC privilégiées.
2	**Catégorie**	Variable la plus discriminante ($V = 0{,}58$, de 5 % à 99 %) : conservée en one-hot.
3	**Nutrition**	Distributions asymétriques, effet faible : `log1p` pour le modèle linéaire.
4	**Portions, manquants**	Aucun effet propre : `nutrition_missing` retirée, portions gardées sans coût.

2

Modélisation

Régression logistique, Random Forest et Gradient Boosting

Démarche de modélisation

1 — Séparation
80 / 20 stratifiée
757 train · 190 test

2 — Prétraitement
Log + standardisation (linéaire), one-hot

3 — Validation croisée
5 plis stratifiés
F1, AUC, précision

4 — Optimisation
GridSearch sur le F1, 3 modèles

5 — Test final
Évaluation sur 190 recettes

Tout le prétraitement est dans des pipelines scikit-learn : pas de fuite de données entre entraînement et validation.

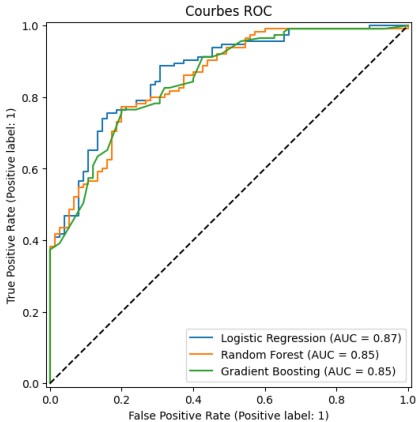
Trois modèles, des scores proches

Modèle	F1 (CV)	Accuracy	Précision	Rappel	F1	ROC AUC
Régression logistique	**0,803**	**0,779**	**0,848**	**0,774**	**0,809**	**0,869**
Random Forest	0,796	0,753	0,788	0,809	0,798	0,852
Gradient Boosting	0,801	0,779	0,854	0,765	0,807	0,850

CV = validation croisée sur le jeu d'entraînement ; autres colonnes = jeu de test (190 recettes).

Écarts de F1 inférieurs à 0,02 : modèles équivalents. Retenu : la régression logistique (meilleure AUC, la plus simple et interprétable).

Courbes ROC des trois modèles



Courbes ROC sur le jeu de test (190 recettes)

0,87

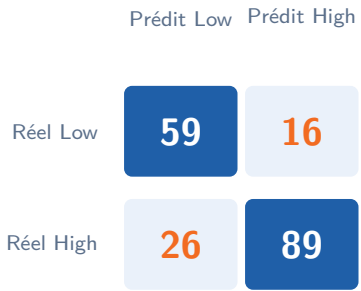
AUC du modèle retenu

Les trois courbes sont très proches et nettement au-dessus de la diagonale (hasard).

L'AUC est la probabilité qu'une recette à fort trafic reçoive un score plus élevé qu'une recette à faible trafic.

Le modèle retenu en détail

Matrice de confusion (test, 190 recettes)



0,85 Précision

Quand le modèle annonce un fort trafic, il a raison 85 fois sur 100.

0,77 Rappel

Il repère 77 % des recettes à fort trafic.

0,87 ROC AUC

Bonne capacité à classer les recettes.

Seuil de décision à 0,5.

Conclusion

À retenir

- La catégorie est le facteur dominant du trafic.
- La nutrition et les portions apportent peu.
- Régression logistique : F1 0,81 et AUC 0,87 sur le test.
- Les trois modèles sont équivalents ; le plus simple est retenu.

Limites et pistes

- Petit échantillon : 947 recettes, 190 en test.
- Pas de données sur les ingrédients ni le temps de préparation.
- Imputation calculée avant la séparation train / test : à intégrer au pipeline.
- Ajuster le seuil selon le coût d'une fausse promotion.

Ouvrir l'application interactive